

## **Controle inteligente de centrais de água gelada utilizando deep learning aplicado a dados sintéticos para o comando de acionamento dos equipamentos**

Pablo Ricardo de Abreu<sup>1\*</sup>; Regina Ávila Santos<sup>2</sup>

<sup>1</sup> USP/ESALQ. Aluno. Avenida Pádua Dias, 11 – Centro; 13418-900, Piracicaba, SP, Brasil

<sup>2</sup> Professora Associada MBA/ESALQ/USP. Mestre em Economia Aplicada. R. Cezira Giovanoni Moretti, 580 - Santa Rosa, Piracicaba, SP, 13414-157, Brasil

\*autor correspondente: pabloabreu1277@gmail.com

## **Controle inteligente de centrais de água gelada utilizando deep learning aplicado a dados sintéticos para o comando de acionamento dos equipamentos**

### **Resumo**

Este trabalho tem como objetivo aprimorar os acionamentos em situações complexas de uma central de água gelada, visando tornar o sistema mais robusto e econômico em termos de consumo de energia elétrica. Para isso, desenvolveu-se um sistema inteligente de controle para unidades Chiller, utilizando rede neural artificial (RNAs) capazes de realizar o ajuste dinâmico de setpoints e a ativação ou desativação automática de Chillers. O sistema foi implementado em Python e R, utilizando técnicas de aprendizado de máquina supervisionado, e validado com dados sintéticos gerados a partir de modelos termodinâmicos simplificados. Resultados mostram que a rede neural alcançou um erro absoluto médio (MAE) de 0.35°C no ajuste do setpoint e uma acurácia de 97.2% na decisão de habilitação. O estudo demonstra que abordagens baseadas em inteligência artificial podem melhorar a eficiência energética e a confiabilidade operacional de sistemas de refrigeração industrial.

**Palavras-chave:** Chiller, Redes Neurais Artificiais, Controle Inteligente, Economia Energética, Aprendizado de Máquina.

### **Intelligent control of chilled water plants using deep learning applied to synthetic data to control equipment activation**

### **Abstract**

This work aims to improve actions in complex situations of a chilled water plant, making the system more robust and economical in terms of electricity consumption. For this purpose, an intelligent control system for Chiller units was developed, using artificial neural networks (ANNs) capable of dynamically adjusting setpoints and automatically activating or deactivating Chillers. The system was implemented in Python and R, using supervised machine learning techniques, and validated with synthetic data generated from simplified thermodynamic models. The results show that the neural network achieved a mean absolute error (MAE) of 0.35°C in adjusting the setpoint and an accuracy of 97.2% in the enabling decision. The study demonstrates that approaches based on artificial intelligence can improve the energy efficiency and operational reliability of industrial refrigeration systems.

**Keywords:** Chiller, Artificial Neural Networks, Intelligent Control, Energy Economy, Machine Learning.

## **Introdução**

No Brasil, a eficiência energética é uma prioridade em edifícios comerciais, especialmente em sistemas de refrigeração Central de Água Gelada [CAG], (Blog do Frio, 2018). Esses sistemas, comuns em escritórios, shoppings, hospitais e hotéis, requerem estratégias de controle eficientes para melhorar o desempenho e reduzir o consumo de energia. Além de ser ambientalmente benéfico, economizar energia ajuda a diminuir a pegada de carbono, mitigando os impactos ambientais e abordando as preocupações crescentes com sustentabilidade e responsabilidade corporativa. (Mercato Automação, 2023).

O consumo de energia em uma nação bem desenvolvida é diversificado, com as edificações representando uma parte significativa desse consumo, especialmente devido aos sistemas de climatização, (Campanhola 2015). Essas estruturas são projetadas para uma variedade de fins, incluindo uso industrial, comercial e residencial. Nos Estados Unidos, as edificações consumiram 41% da energia primária em 2010, sendo que metade desse consumo foi destinado à climatização, (DOE 2012). Os custos associados à energia nas edificações são principalmente atribuídos à climatização, devido à crescente demanda por conforto térmico e segurança de produtos. A escolha de sistemas de climatização adequados desempenha um papel essencial na melhoria da eficiência energética do sistema, levando em consideração as características específicas e as restrições de cada edificação. (Rafael Augusto, 2018).

A base da tecnologia de refrigeração é fundamentada no ciclo de compressão de vapor (ASHRAE, 2017). As variações nas soluções de refrigeração surgem de diferentes abordagens no ciclo, tais como sistemas de expansão direta e sistemas de expansão indireta. No contexto de ambientes comerciais, os sistemas de água gelada são amplamente adotados como uma das principais soluções para o condicionamento de ar. CAG têm sido líderes desde o início do século XX e são amplamente empregados, especialmente em locais com alta demanda de carga térmica (CARRIER, 2019). Esses sistemas operam com um fluido refrigerante que não circula pelo ambiente interno, sendo a água o fluido de trabalho predominante. O componente externo responsável pelo resfriamento da água é conhecido como chiller, que bombeia a água para as unidades de tratamento de ar [UTA], “Fancoils”, “Selfs” e etc. Essas unidades são encarregadas de resfriar e filtrar o ar ambiente (ASHRAE, 2016). O uso mais frequente de água gelada está associado a sistemas centrais, nos quais o dimensionamento é realizado para toda a edificação em um único sistema. (CONBRAVA, 2019).

Dentre os sistemas a CAG atende locais que utilizam ar-condicionado centrais, onde esses sistemas utilizam essa água gelada para resfriar o ar do ambiente desejado, utilizando radiadores para retirar o calor do Ar, onde a água passa por tubos capilares com aletas em uma vazão projetada, essa água quente depois de passar por esse processo de troca de calor é enviada para torres de resfriamento ou retornam para a Central dependendo do projeto do chiller que foi instalado. O ar que enviamos para o ambiente geralmente é filtrado, através de ventiladores realizamos o insuflamento ou a exaustão do ambiente.

O conjunto da central é composto por um ou mais chillers, unidades de resfriamento, um reservatório de água para reposição da água perdida devido a evaporação natural e vazamentos, bombas de água gelada que enviamos para o consumo, chamamos de sistema Secundário, bombas de água de resfriamento que enviamos para o chiller, que chamamos de sistema Primário. O chiller é responsável por produzir a troca térmica na água, as bombas são utilizadas para distribuir a água gelada pelo sistema de resfriamento do prédio, podemos ter várias configurações como sistema barrilete que projeto das tubulações permite o uso das bombas em paralelo, configurações de tubulações do modo dedicado onde são individualizados os usos dos conjuntos de bombas e chillers.

Na automação de uma CAG, as tarefas executadas manualmente podem ser automatizadas por um dispositivo de controle conhecido como Controlador Lógico Programável [CLP], sensores para telemetria do sistema em geral como sensores de pressão, nível e temperatura, atuadores como válvulas “on/off”, válvulas proporcionais e balanceadoras. Operações como ligar e desligar dispositivos, ativar máquinas conforme a dinâmica do sistema, detectar falhas, realizar o rodízio de carga e monitorar variáveis do processo. Essas operações podem ser programadas em diferentes linguagens para CLP. (Flávio Quiel, 2023).

O CLP recebe as leituras dos sensores, através de lógica pura liga/desliga ou uso do método Controle Proporcional Integral Derivativo [PID], envia os comandos para os atuadores e equipamentos, como por exemplo: ao atingir o setpoint de pressão na linha primária, as bombas primárias serão ligadas em uma frequência de x Hz, caso essa pressão começar a variar a frequência da bomba também se altera proporcionalmente com o objetivo de atingir o setpoint determinado.

Uma nova abordagem é utilizar aprendizagem de máquina com redes neurais artificiais [RNAs] para melhorar a adaptabilidade a mudanças nas condições do sistema e geralmente podem lidar melhor com sistemas complexos e não lineares. Os controladores PID são construídos com base em um modelo matemático que emprega “feedback” para ajustar constantemente os parâmetros do sistema, incluindo ganho proporcional, tempo integral e tempo derivativo, (Åström e Richard, 2008). Os sistemas de controle utilizando

“Deep Learning” fazem uso de algoritmos de aprendizado de máquina complexos para extrair padrões diretamente dos dados de entrada, eliminando a necessidade de um modelo matemático explícito. Ao invés disso, esses sistemas aprendem padrões e relações complexas diretamente dos dados de entrada, tornando-os mais adequados para sistemas com comportamentos não lineares ou pouco definidos. (Maithra e Eric, 2020).

Neste artigo, é proposta uma abordagem pouco comum na literatura existente onde se usa controladores por PID. Aplicamos um modelo de RNA para o controle de equipamentos e ajuste de “setpoint”. O objetivo é aprimorar os acionamentos em situações complexas de uma central de água gelada, visando tornar o sistema mais robusto e econômico em termos de consumo de energia elétrica. Essa melhoria visa atender à demanda por maior eficiência e desempenho dos ativos nos edifícios.

## **Material e Métodos**

### **Geração de Dados Sintéticos**

A primeira etapa do desenvolvimento do modelo de controle inteligente consistiu na geração de um conjunto de dados sintéticos, que simulam o comportamento real de um sistema de Chiller operando sob diferentes condições ambientais e operacionais. Esta escolha se justifica pela necessidade de ampla variabilidade e controle sobre os dados, além de evitar custos e riscos associados à coleta em campo.

#### **Temperaturas Ambiente, Entrada e Saída:**

Foram geradas seguindo uma distribuição normal (Gaussiana), centrada em valores típicos de operação industrial (ex.: temperatura ambiente média de 25°C com desvio padrão de 5°C). A temperatura de entrada no Chiller foi modelada como sendo ligeiramente superior à de saída, com variação em torno de  $\pm 3^\circ\text{C}$ , representando ganhos ou perdas térmicas no processo.

#### **Pressão da Água:**

A pressão da água foi correlacionada proporcionalmente ao fluxo, utilizando uma equação linear simplificada do tipo  $P = a \times Q + b$ , onde  $P$  é a pressão,  $Q$  é o fluxo de água e  $a, b$  são coeficientes ajustados para simular perdas de carga e resistência hidráulica.

#### **Status de Bombas e Válvulas:**

Os estados (ligado/desligado) das bombas primária e secundária e da válvula de bloqueio foram determinados através de uma lógica condicional baseada em valores de

pressão, temperatura e demanda de resfriamento. Se, por exemplo, a pressão caísse abaixo de determinado limiar, a válvula de bloqueio seria fechada automaticamente, simulando um controle de emergência realista. Essa abordagem permitiu gerar um conjunto robusto de amostras, garantindo diversidade suficiente para o treinamento de redes neurais sem viés de sobreajuste.

## **Arquitetura da Rede Neural**

A rede neural proposta foi desenvolvida com base no paradigma de aprendizado supervisionado multi-tarefa, visando otimizar simultaneamente duas saídas: o ajuste do setpoint de temperatura e a habilitação binária do sistema Chiller. A estrutura da rede foi cuidadosamente elaborada para garantir capacidade de generalização, robustez contra sobreajuste (overfitting) e adequação à natureza mista dos dados (contínuos e categóricos).

### **Camada de Entrada**

O vetor de entrada da rede é composto por 8 variáveis independentes, previamente normalizadas para o intervalo  $[0,1]$ , visando acelerar o processo de convergência durante o treinamento. As entradas representam:

- $x_1$ : Temperatura ambiente ( $^{\circ}\text{C}$ )
- $x_2$ : Temperatura de entrada do Chiller ( $^{\circ}\text{C}$ )
- $x_3$ : Temperatura de saída do Chiller ( $^{\circ}\text{C}$ )
- $x_4$ : Pressão da água na linha de saída (bar)
- $x_5$ : Setpoint inicial de temperatura ( $^{\circ}\text{C}$ )
- $x_6$ : Status da bomba primária (0 = desligada, 1 = ligada)
- $x_7$ : Status da bomba secundária (0 = desligada, 1 = ligada)
- $x_8$ : Status da válvula de bloqueio (0 = fechada, 1 = aberta)

## Camadas Ocultas

A arquitetura interna da rede consiste em três camadas densas (todas conectadas), com número crescente e decrescente de neurônios, permitindo uma boa abstração das representações de alto nível:

- 1ª camada oculta: 64 neurônios com ativação ReLU.
- 2ª camada oculta: 128 neurônios com ativação ReLU.
- 3ª camada oculta: 64 neurônios com ativação ReLU.

Unidade Linear Retificada [ReLU], produz resultados dentre  $[0, \infty[$ . Essa função retorna 0 para todos os valores negativos, e o próprio valor para valores positivos. (Denny Ceccon, 2020).

Para mitigar o risco de overfitting e melhorar a capacidade de generalização do modelo, cada camada é seguida por uma camada Dropout com taxa  $p=0,2$ , ou seja, 20% dos neurônios são desativados aleatoriamente durante cada iteração de treinamento.

## Camadas de Saída

A estrutura da rede adota uma abordagem de saída dupla “multi-head”, otimizando simultaneamente uma tarefa de regressão e uma de classificação binária:

- Saída 1 – Regressão do ajuste de setpoint
  - Neurônio único com ativação linear.
  - Output:  $y_1$ , pertence ao conjunto de números reais, valor contínuo representando a diferença a ser somada ou subtraída ao setpoint inicial.
- Saída 2 – Classificação de habilitação do Chiller
  - Neurônio único com ativação sigmoide.
  - Output:  $y_2 \in [0,1]$ , representando a probabilidade de o Chiller estar habilitado (com limiar de 0,5 para decisão final).

Essa abordagem multi-tarefa permite que o modelo aprenda representações compartilhadas nas camadas ocultas, otimizando o desempenho global ao aproveitar correlações entre os ajustes térmicos e o estado dos dispositivos periféricos (bombas e válvulas).



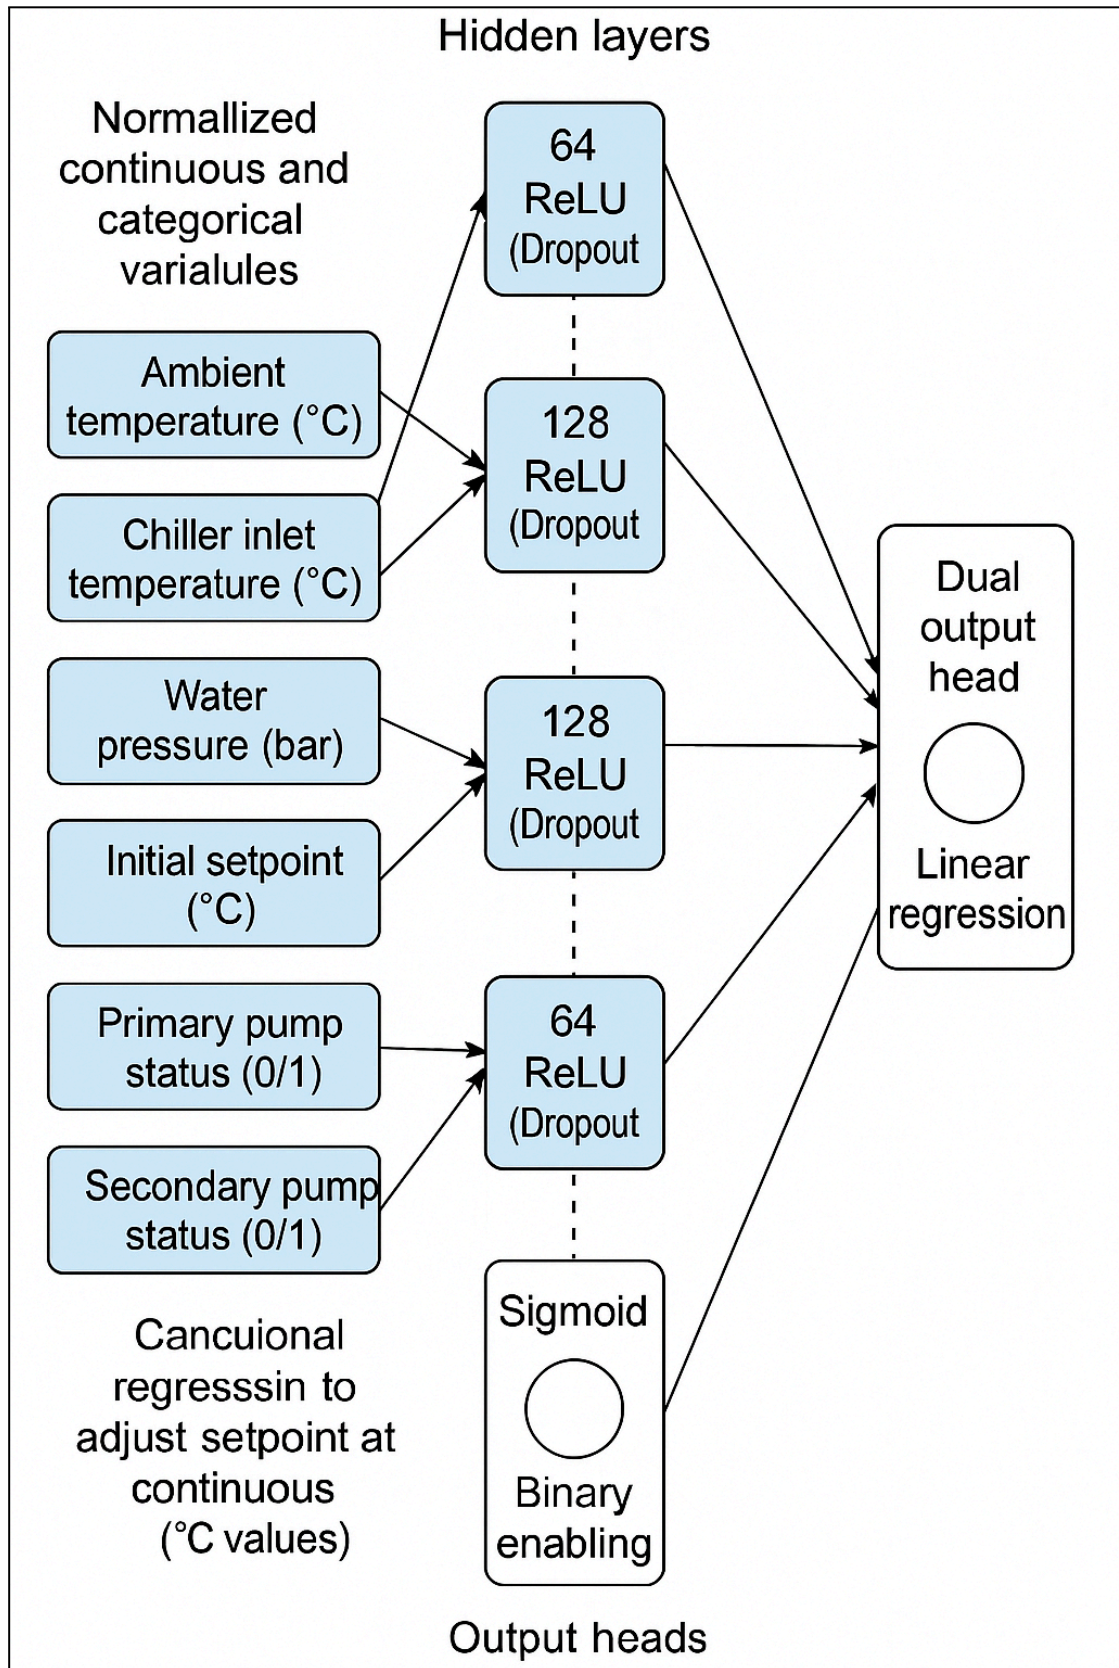


Figura 01 - Arquitetura da rede neural controle inteligente. Fonte: Elaboração própria.



## **Treinamento e Validação**

O treinamento do modelo seguiu práticas recomendadas para redes neurais profundas:

Otimizador: Utilizou-se o otimizador Adam (Adaptive Moment Estimation), por ser eficiente para problemas com alta dimensionalidade, configurado com uma taxa de aprendizado inicial de 0,001.

Funções de Custo: Regressão: Erro Absoluto Médio (MAE) e Raiz do Erro Quadrático Médio (RMSE) foram monitorados.

Classificação: Acurácia e Área sob a Curva ROC (AUC) foram utilizadas para avaliar a capacidade de distinguir entre classes (habilitar ou não o Chiller).

Técnicas Anti-Overfitting:

“Early Stopping”: O treinamento foi interrompido automaticamente se a métrica de validação não melhorasse após 10 épocas consecutivas, evitando o “overfitting”.

“ReduceLROnPlateau”: Reduziu dinamicamente a taxa de aprendizado em 50% sempre que a validação estagnou, permitindo uma convergência mais refinada.

O conjunto de dados foi dividido em:

70% para treinamento,

15% para validação,

15% para teste.

A separação foi aleatória, respeitando a distribuição estatística das variáveis.

## **Resultados e Discussão**

Para a aplicação prática do estudo, o controle proposto neste artigo foi comparado ao desempenho de um equipamento real, conforme descrito a seguir. Chiller Scroll Inverter, modelo ACAH020LETB-CO, Marca LG, Capacidade de refrigeração 65kW ou 18TR (toneladas de refrigeração).

Realizando um comparativo utilizamos o seguinte raciocínio de cálculo:

Assumimos COP constante como 0,85 (ou 85%) para efeito comparativo. A equação do COP real seria:

$$COP = \frac{Q}{P} \Rightarrow P = \frac{Q}{0,85}$$

Com Setpoint Inicial de 6 °C:

$$Q_{\text{inicial}} = 40 \text{ kW} \Rightarrow P_{\text{inicial}} = \frac{40}{0,85} \approx 47,06 \text{ kW}$$

Com Setpoint Ajustado para 9 °C:

Admite-se que o aumento do setpoint reduz a carga térmica proporcionalmente. Considerando uma redução de 7,5% na carga devido à menor diferença de temperatura entre o ambiente e a água refrigerada:

$$Q_{\text{ajustado}} = 40 \times (1 - 0,075) = 37,0 \text{ kW} \Rightarrow P_{\text{ajustado}} = \frac{37}{0,85} \approx 43,53 \text{ kW}$$

Economia Estimada de Energia por Hora:

$$\Delta P = P_{\text{inicial}} - P_{\text{ajustado}} = 47,06 - 43,53 = 3,53 \text{ kWh}$$

## **Conclusão(ões) ou Considerações Finais**

O trabalho apresentou resultados significativos

## **Agradecimento**

Agradeço a minha querida esposa, pela dedicação, cuidado e suporte em todos os momentos – sua parceria foi fundamental para que este trabalho se tornasse realidade. Agradeço aos meus pais por ter me dado a base e a determinação em sempre seguir em frente. E, acima de tudo, agradeço a Jesus Cristo, por ser meu pastor e não deixar nada faltar na vida da minha família.

## **Referências**

Mercato Automação. 16 agosto 2023. Disponível em:

<<https://www.mercatoautomacao.com.br/blogs/novidades/automacao-predial-e-eficiencia-en-energetica-para-centrais-de-agua-gelada>>. Acesso em: 30 março 2024.

Blog do Frio. 04 outubro 2018. Disponível em:<<https://blogdofrio.com.br/retrofit-e-manutencao-preventiva-elevam-eficiencia-de-centrais-de-agua-gelada/>>. Acesso em: 28 de abril de 2025.

Expert Academy. 25 de maio de 2020. Disponível em: <<https://iaexpert.academy/2020/05/25/funcoes-de-ativacao-definicao-caracteristicas-e-quando-usar-cada-uma/#:~:text=ReLU%20%C3%A9%20uma%20abrevia%C3%A7%C3%A3o%20para,n%C3%A3o%20%C3%A9%20centrada%20em%20zero.>>. Acesso em: 28 de abril de 2025.

XVI CONBRAVA - Congresso Brasileiro de Refrigeração, ar-condicionado, ventilação, aquecimento e tratamento do ar São Paulo Expo - 10 a 13 de setembro de 2019. Disponível em: <[https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto\\_54.pdf](https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto_54.pdf)> Acesso em: 30 março 2024.

XVI CONBRAVA - Congresso Brasileiro de Refrigeração, ar-condicionado, ventilação, aquecimento e tratamento do ar São Paulo Expo - 10 a 13 de setembro de 2019. Disponível em: <[https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto\\_61.pdf](https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto_61.pdf)> Acesso em: 30 março 2024.

Rafael Augusto Fiametti. Estudo de caso: eficiência energética em sistemas de climatização por água gelada. 2018. Disponível em: <[https://repositorio.utfpr.edu.br/jspui/bitstream/1/18500/1/CT\\_CEEFE\\_V\\_2016\\_05.pdf](https://repositorio.utfpr.edu.br/jspui/bitstream/1/18500/1/CT_CEEFE_V_2016_05.pdf)>. Acesso em: 01 abril 2024.

Flávio Quiel de Azevedo neto. Automação de uma central de água gelada para climatização de salas de cinemas: um estudo de caso. 2023. Disponível em: <[https://www.monografias.ufop.br/bitstream/35400000/6001/6/MONOGRAFIA\\_Automa%c3%a7%c3%a3oCentral%c3%81gua.pdf](https://www.monografias.ufop.br/bitstream/35400000/6001/6/MONOGRAFIA_Automa%c3%a7%c3%a3oCentral%c3%81gua.pdf)>. Acesso em: 01 abril 2024.

Åström, Karl Johan, e Richard M. Murray. Feedback Systems: An Introduction for Scientists and Engineers. Princeton University Press, 2008. Disponível em: <[https://www.cds.caltech.edu/~murray/books/AM05/pdf/am08-complete\\_28Sep12.pdf](https://www.cds.caltech.edu/~murray/books/AM05/pdf/am08-complete_28Sep12.pdf)>. Acesso em: 01 abril 2024.

Maithra Raghu, e Eric Schmidt. 2020 A Survey of Deep Learning for Scientific Discovery. Disponível em: <<https://arxiv.org/pdf/2003.11755.pdf>> Acesso em: 30 março 2024.

Remessa Online. Linguagem R: entenda como funciona e principais aplicações. Remessa Online, 1 Maio 2023. Disponível em: <<https://www.remessaonline.com.br/blog/linguagem-r-entenda-como-funciona-e-principais-aplicacoes/>> Acesso em: 1 abril 2024.

Ronaldo Almeida. Como definir uma CAG eficiente? - Portal EA. Engenharia e Arquitetura, 23 Janeiro 2020. Disponível

em: <<https://www.engenhariae arquitetura.com.br/2020/01/como-definir-uma-cag-eficiente>>.  
Acesso em: 30 março 2024.

ASHRAE (2019). Handbook—HVAC Applications. Atlanta: ASHRAE.

Afram, A., & Janabi-Sharifi, F. (2014). Artificial neural network-based control of HVAC systems. *Energy and Buildings*, 77, 403-414.

Li, X. et al. (2021). Deep learning for smart HVAC control. *Applied Energy*, 291, 116823.

Zhang, L. et al. (2020). PID vs. AI-based control in HVAC systems. *Energy*, 197, 117245.

Zhao, Y. et al. (2020). Fault detection in chillers using neural networks. *Building and Environment*, 167, 106462.

### **Apêndice ou Anexo (opcional)**

Os apêndices são textos e/ou documentos que foram elaborados pelos autores e que são importantes para complementar a argumentação do trabalho. Anexos são textos ou documentos que ilustram o trabalho, mas que não foram elaborados pelos autores. Apêndices deverão seguir as mesmas normas de formatação do restante do texto, inclusive para as figuras e tabelas.

O TCC deverá conter no máximo 30 páginas, incluindo o(s) Apêndice(s) e/ou Anexo(s).

**Atenção:** antes de enviar o arquivo para o Sistema de TCCs, remova todas as instruções originais que estão abaixo do conteúdo dos tópicos.