

Controle inteligente de centrais de água gelada utilizando deep learning aplicado a dados sintéticos para o comando de acionamento dos equipamentos

Pablo Ricardo de Abreu^{1*}; Regina Ávila Santos²

¹ USP/ESALQ. Aluno. Avenida Pádua Dias, 11 – Centro; 13418-900, Piracicaba, SP, Brasil

² Professora Associada MBA/ESALQ/USP. Mestre em Economia Aplicada.R. Cezira Giovanoni Moretti, 580 - Santa Rosa, Piracicaba, SP, 13414-157, Brasil

*autor correspondente: pabloabreu1277@gmail.com

Controle inteligente de centrais de água gelada utilizando deep learning aplicado a dados sintéticos para o comando de acionamento dos equipamentos

Resumo

Este trabalho tem como objetivo aprimorar os acionamentos em situações complexas de uma central de água gelada, visando tornar o sistema mais robusto e econômico em termos de consumo de energia elétrica. Para isso, desenvolveu-se um sistema inteligente de controle para unidades Chiller, utilizando rede neural artificial (RNA) com múltiplas saídas, capaz de prever diretamente o setpoint ótimo absoluto e determinar a ativação ou desativação automática de Chillers.

O sistema foi implementado em Python, utilizando *TensorFlow* para o desenvolvimento da rede neural com camadas densas, regularização L2 e técnicas de Dropout para evitar o overfitting. O modelo foi validado com dados sintéticos gerados a partir de heurísticas que simulam condições operacionais de Chillers. Resultados mostram que a versão final da rede neural alcançou um MAE de aproximadamente 0.06°C na previsão do ótimo setpoint e uma acurácia de 100% na decisão de habilitação.

Simulações comparativas com diferentes cenários, incluindo setpoints fixos e condições forçadas de operação, demonstraram que a abordagem baseada em inteligência artificial pode influenciar significativamente o consumo energético, embora nem sempre resultando em economia. O estudo evidencia o potencial das redes neurais para otimização de sistemas de refrigeração industrial.

Palavras-chave: Chiller, Redes Neurais Artificiais, Controle Inteligente, Economia Energética, Aprendizado de Máquina.

Intelligent Control of Chilled Water Plants Using Deep Learning Applied to Synthetic Data for Equipment Activation Command

Abstract

This work aims to improve the activation processes in complex situations of a chilled water plant, making the system more robust and economical in terms of electrical energy consumption. To achieve this, an intelligent control system for Chiller units was developed, using artificial neural networks (ANNs) with multiple outputs, capable of directly predicting the absolute optimal setpoint and determining the automatic activation or deactivation of Chillers. The system was implemented in Python, using TensorFlow for the development of the neural network with dense layers, L2 regularization, and Dropout techniques to prevent overfitting. The model was validated with synthetic data generated from heuristics that simulate Chiller operational conditions. Results show that the final version of the neural network (Model V2) achieved an MAE of approximately 0.06°C in optimal setpoint prediction and 100% accuracy in the enabling decision.

Comparative simulations with different scenarios, including fixed setpoints and forced operating conditions, demonstrated that the artificial intelligence-based approach can significantly influence energy consumption, although not always resulting in savings. The study highlights the potential of neural networks for optimizing industrial refrigeration systems.

Keywords: Chiller, Artificial Neural Networks, Intelligent Control, Energy Savings, Machine Learning.

Introdução

A busca por eficiência energética tornou-se prioridade em edificações comerciais, especialmente nos sistemas de climatização centralizados, como as Centrais de Água Gelada (CAG). Esses sistemas são amplamente utilizados em hospitais, shoppings, hotéis e edifícios corporativos, nos quais a climatização representa parcela significativa do consumo elétrico (Blog do Frio, 2018; Mercado Automação, 2023). Além de contribuir para a sustentabilidade ambiental, a redução desse consumo possibilita a diminuição da pegada de carbono, alinhando-se às atuais demandas de responsabilidade socioambiental.

Estudos apontam que a climatização corresponde a uma fração expressiva da energia consumida em edificações. Nos Estados Unidos, por exemplo, cerca de 41% da energia primária em 2010 foi destinada a edifícios, sendo metade desse montante relacionada ao condicionamento de ar (DOE, 2012). No Brasil, a realidade não é distinta, uma vez que a expansão urbana e a crescente demanda por conforto térmico tornam os sistemas de refrigeração protagonistas no consumo energético (Campanhola, 2015; Rafael Augusto, 2018).

A tecnologia de refrigeração aplicada em CAG baseia-se no ciclo de compressão de vapor (ASHRAE, 2017). Esse sistema opera com chillers responsáveis por resfriar a água que circula até unidades de tratamento de ar, fancoils e demais equipamentos de climatização. Para o funcionamento eficiente, a central é composta por bombas, reservatórios, válvulas e dispositivos auxiliares, cuja operação integrada impacta diretamente o desempenho energético (ASHRAE, 2016; Carrier, 2019; CONBRAVA, 2019).

Tradicionalmente, o controle das CAG é realizado por meio de Controladores Lógicos Programáveis (CLPs), empregando estratégias clássicas como o Controle Proporcional-Integral-Derivativo (PID). Embora robustos e amplamente consolidados, esses controladores apresentam limitações diante da natureza dinâmica e não linear dos sistemas de climatização, dificultando ajustes finos e ocasionando, em muitos casos, desperdícios energéticos (Åström e Richard, 2008; Flávio Quiel, 2023).

Nesse contexto, técnicas baseadas em inteligência artificial, em especial as Redes Neurais Artificiais (RNAs), emergem como alternativas promissoras. Diferentemente dos métodos convencionais, as RNAs são capazes de extrair padrões diretamente dos dados, dispensando modelos matemáticos explícitos. Isso permite maior adaptabilidade frente às variações de carga térmica e às condições operacionais, possibilitando a melhoria no desempenho do sistema (Maithra e Eric, 2020).

Diante desse cenário, o presente trabalho propõe o uso de uma arquitetura de rede neural profunda aplicada ao controle de chillers em centrais de água gelada, com ênfase no ajuste automático de setpoints e na habilitação otimizada dos equipamentos. O objetivo é aprimorar a eficiência energética e a confiabilidade operacional, contribuindo para a gestão inteligente de edificações e para a redução do consumo de energia elétrica em larga escala.

Material e Métodos

Geração de Dados Sintéticos:

A primeira etapa do desenvolvimento consistiu na criação de um conjunto de dados sintéticos, utilizado para treinar e validar a rede neural artificial proposta. Optou-se pela geração de dados simulados em virtude da necessidade de ampla variabilidade controlada, bem como da redução de custos e riscos associados à coleta em campo, prática comum em estudos de automação de sistemas HVAC (Heating, Ventilation and Air Conditioning).

O dataset foi gerado por meio de rotinas em Python, utilizando as bibliotecas NumPy e Pandas. Foram produzidas 2.000 amostras, contemplando variáveis de entrada que caracterizam o funcionamento de uma Central de Água Gelada (CAG):

Temperatura ambiente (°C): valores gerados entre 0 e 50 °C, representando diferentes condições externas.

Temperatura de entrada no chiller (°C): distribuída entre 5 e 40 °C.

Temperatura de saída do chiller (°C): modelada condicionalmente em função da operação das bombas, válvulas e pressão de água, garantindo coerência física entre entrada e saída. Valores abaixo de 1 °C foram evitados para não comprometer a plausibilidade.

Pressão da água na saída (bar): valores entre 1 e 5 bar, simulando variações hidráulicas reais.

Setpoint inicial (°C): definido entre 4 e 15 °C, representando as condições típicas de operação.

Status de bombas e válvulas: variáveis binárias (0 ou 1) para bomba primária, bomba secundária e válvula de bloqueio, simulando estados de operação.

As saídas do dataset foram definidas a partir de regras de lógica condicional:

Comando de habilitação (0 ou 1): indica se o chiller estaria apto a operar, considerando condições hidráulicas e térmicas adequadas.

Ajuste de setpoint (°C): calculado em função da diferença entre temperatura de saída e setpoint inicial, incluindo influência da temperatura ambiente e eficiência térmica do chiller.

Esse processo de modelagem assegurou que os dados apresentassem consistência física e diversidade operacional, permitindo o treinamento da rede neural em cenários que representassem variações realistas de carga térmica e desempenho do sistema.

Validação dos Dados Sintéticos:

Revisão das distribuições estatísticas das variáveis, verificando se as amplitudes e médias se aproximavam de valores típicos reportados na literatura de HVAC (ASHRAE, 2016; CONBRAVA, 2019).

Conferência de coerência operacional, assegurando que as relações entre entrada e saída respeitassem princípios físicos (ex.: temperatura de saída \leq temperatura de entrada; pressão mínima para habilitação do sistema).

Teste de robustez, avaliando a diversidade do conjunto e reduzindo o risco de viés no treinamento da rede neural.

A escolha da arquitetura baseou-se em duas características do problema:

Não linearidade do sistema: os processos térmicos e hidráulicos de uma CAG apresentam comportamento altamente não linear, o que dificulta a modelagem via controladores convencionais como o PID (Åström e Richard, 2008).

Aprendizado direto a partir dos dados: as redes neurais profundas permitem identificar padrões complexos sem necessidade de formulação explícita de modelos matemáticos, o que favorece sua aplicação em sistemas dinâmicos e variáveis (Maithra e Eric, 2020).

Dessa forma, adotou-se uma rede neural profunda (Deep Neural Network – DNN) do tipo feedforward, com múltiplas camadas ocultas e funções de ativação não lineares (ReLU), visando maximizar a capacidade de generalização. Essa escolha encontra respaldo na literatura que destaca a superioridade das DNNs em tarefas de previsão e controle em sistemas HVAC (ASHRAE, 2017; Carrier, 2019).

Arquitetura da Rede Neural:

A rede neural proposta foi desenvolvida com base no paradigma de aprendizado supervisionado multi-tarefa, visando otimizar simultaneamente duas saídas: o ajuste do setpoint de temperatura e a habilitação binária do sistema Chiller. A estrutura da rede foi cuidadosamente elaborada para garantir capacidade de generalização, robustez contra sobreajuste (overfitting) e adequação à natureza mista dos dados (contínuos e categóricos).

Camada de Entrada:

O vetor de entrada da rede é composto por 8 variáveis independentes, representadas pela cor azul conforme figura 01, previamente normalizadas para o intervalo [0,1], visando acelerar o processo de convergência durante o treinamento. As entradas representam:

- 1: Temperatura ambiente (°C)
- 2: Temperatura de entrada do Chiller (°C)
- 3: Temperatura de saída do Chiller (°C)
- 4: Pressão da água na linha de saída (bar)
- 5: Setpoint inicial de temperatura (°C)
- 6: Status da bomba primária (0 = desligada, 1 = ligada)
- 7: Status da bomba secundária (0 = desligada, 1 = ligada)
- 8: Status da válvula de bloqueio (0 = fechada, 1 = aberta)

Camadas Ocultas:

A rede neural proposta neste trabalho possui três camadas ocultas densamente conectadas, representadas pela cor laranja conforme figura 01, organizadas em uma configuração decrescente de neurônios ($128 \rightarrow 64 \rightarrow 32$), com função de ativação ReLU. Essa arquitetura foi escolhida para permitir a aprendizagem hierárquica e progressiva das representações dos dados de entrada, promovendo extração eficiente de padrões complexos e redução do risco de sobreajuste.

A primeira camada oculta, composta por 128 neurônios, tem como objetivo capturar padrões detalhados e interações não lineares presentes nos dados de entrada. A quantidade de neurônios foi selecionada para oferecer capacidade suficiente de aprendizagem sem tornar a rede excessivamente complexa, garantindo equilíbrio entre representação de características e generalização (Goodfellow et al., 2016).

A segunda camada oculta, com 64 neurônios, atua como intermediária, refinando e consolidando as informações extraídas pela camada anterior. Essa redução no número de neurônios permite que a rede foque em características relevantes, evitando a memorização de padrões específicos do conjunto de treinamento e promovendo melhor desempenho em dados não vistos (Chollet, 2017; Nielsen, 2015).

A terceira camada oculta, com 32 neurônios, realiza uma compressão adicional das representações, preparando os dados para a camada de saída. A diminuição progressiva do número de neurônios segue o formato em “pirâmide”, que favorece a aprendizagem hierárquica, equilibrando a complexidade da rede e sua capacidade de generalização (Goodfellow et al., 2016; Chollet, 2017).

A função de ativação ReLU (*Rectified Linear Unit*, Unidade Linear Retificada) foi adotada em todas as camadas ocultas devido à sua eficiência no treinamento de redes profundas e à capacidade de reduzir problemas relacionados a gradientes saturados, comuns em função sigmoid. Representada pela cor verde conforme a figura 01.

ReLU (Rectified Linear Unit): $f(x) = \max(0, x)$

Usada nas camadas ocultas para não-linearidade e eficiência.

Linear: $f(x) = x$

Usada na saída de regressão (ajuste do setpoint).

Sigmoid: $f(x) = 1 / (1 + e^{-x})$

Usada na saída de classificação (comando de habilitação).

Camadas de Saída:

A estrutura da rede adota uma abordagem de saída dupla “multi-head”, otimizando simultaneamente uma tarefa de regressão e uma de classificação binária:

- Saída 1 – Regressão do ajuste de setpoint, representada pela cor roxa conforme figura 01.
 - Neurônio único com ativação linear.
 - Output: y_1 , pertence ao conjunto de números reais, valor contínuo representando a diferença a ser somada ou subtraída ao setpoint inicial.
- Saída 2 – Classificação de habilitação do Chiller, representada pela cor vermelha conforme a figura 01.
 - Neurônio único com ativação sigmoide.
 - Output: $y_2 \in [0,1]$, representando a probabilidade de o Chiller estar habilitado (com limiar de 0,5 para decisão final).

Essa abordagem multi-tarefa permite que o modelo aprenda representações compartilhadas nas camadas ocultas, otimizando o desempenho global ao aproveitar correlações entre os ajustes térmicos e o estado dos dispositivos periféricos (bombas e válvulas).

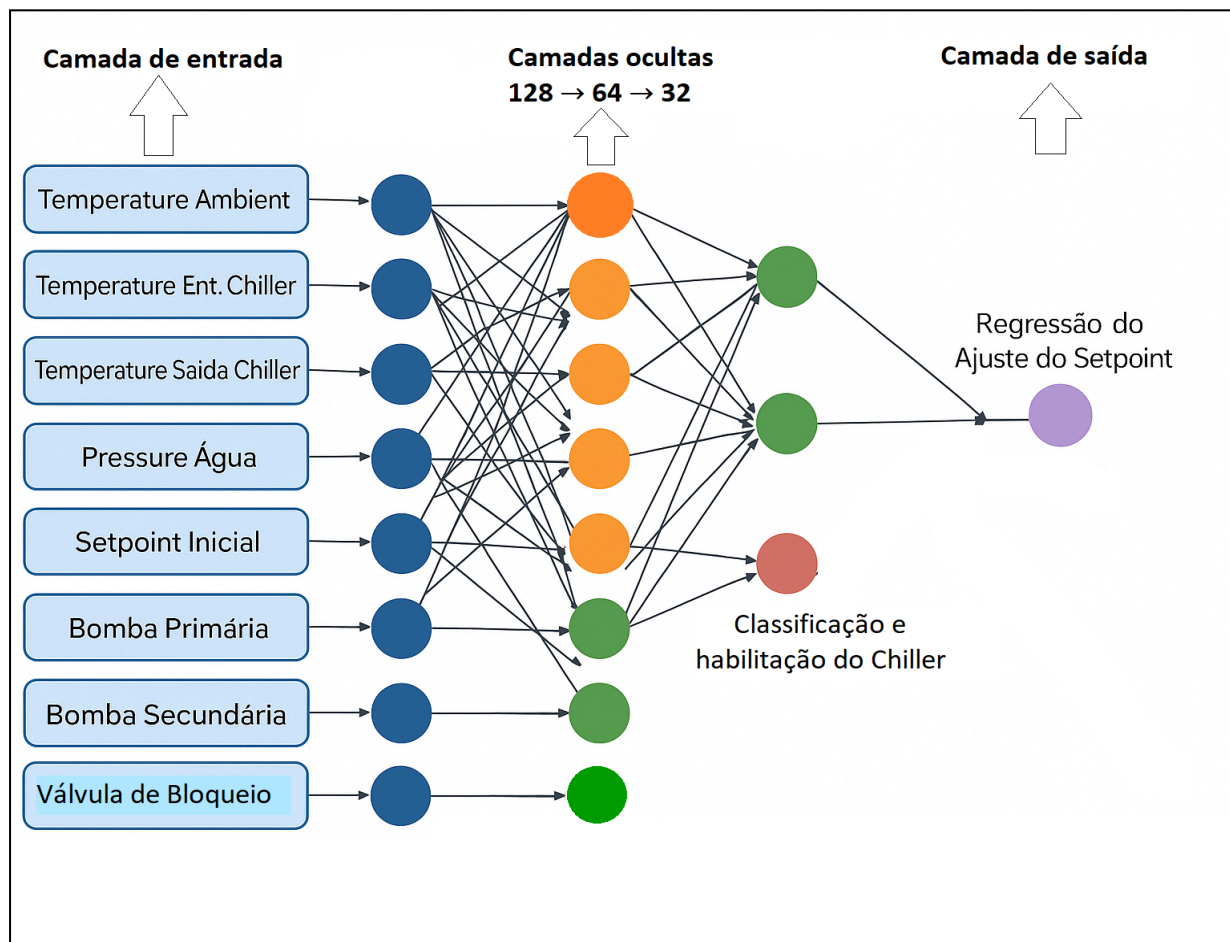


Figura 01 -Arquitetura da rede neural para processamento e tomada de decisão no controle inteligente

Fonte: Elaboração do autor

Treinamento e Validação:

O modelo de rede neural foi treinado utilizando entradas normalizadas via *Standard Scaler*, garantindo que todas as variáveis apresentassem média zero e desvio padrão unitário, prática recomendada para redes neurais profundas (Goodfellow et al., 2016). Os dados foram divididos em 80% para treino e 20% para teste, permitindo avaliação do desempenho em dados não vistos e mitigando risco de sobreajuste (*overfitting*) (Hastie et al., 2009).

O otimizador Adam foi selecionado por combinar técnicas de momento e adaptação de taxa de aprendizado, favorecendo a convergência rápida em problemas de alta dimensionalidade (Kingma & Ba, 2015). Para a tarefa de regressão do setpoint de temperatura, utilizou-se a função de perda MSE, monitorada também pela métrica MAE, garantindo penalização proporcional aos erros e interpretação direta (Chollet, 2017). Para a tarefa de classificação binária da habilitação do Chiller, a função *Binary Crossentropy* foi adotada, com acurácia como métrica de desempenho.

O treinamento foi realizado por até 200 épocas, com a aplicação de *Early Stopping* (paciência de 10 épocas) para prevenir *overfitting*, e *ReduceLROnPlateau* para ajuste dinâmico da taxa de aprendizado, assegurando refinamento na convergência. Um tamanho de lote (*Batch Size*) de 32 foi utilizado, proporcionando equilíbrio entre estabilidade do gradiente e eficiência computacional.

Essas escolhas metodológicas asseguram que o modelo apresenta alta capacidade de generalização, robustez e precisão na previsão do setpoint e na habilitação do sistema Chiller, em conformidade com as melhores práticas de aprendizado profundo multitarefa (Goodfellow et al., 2016; Chollet, 2017).

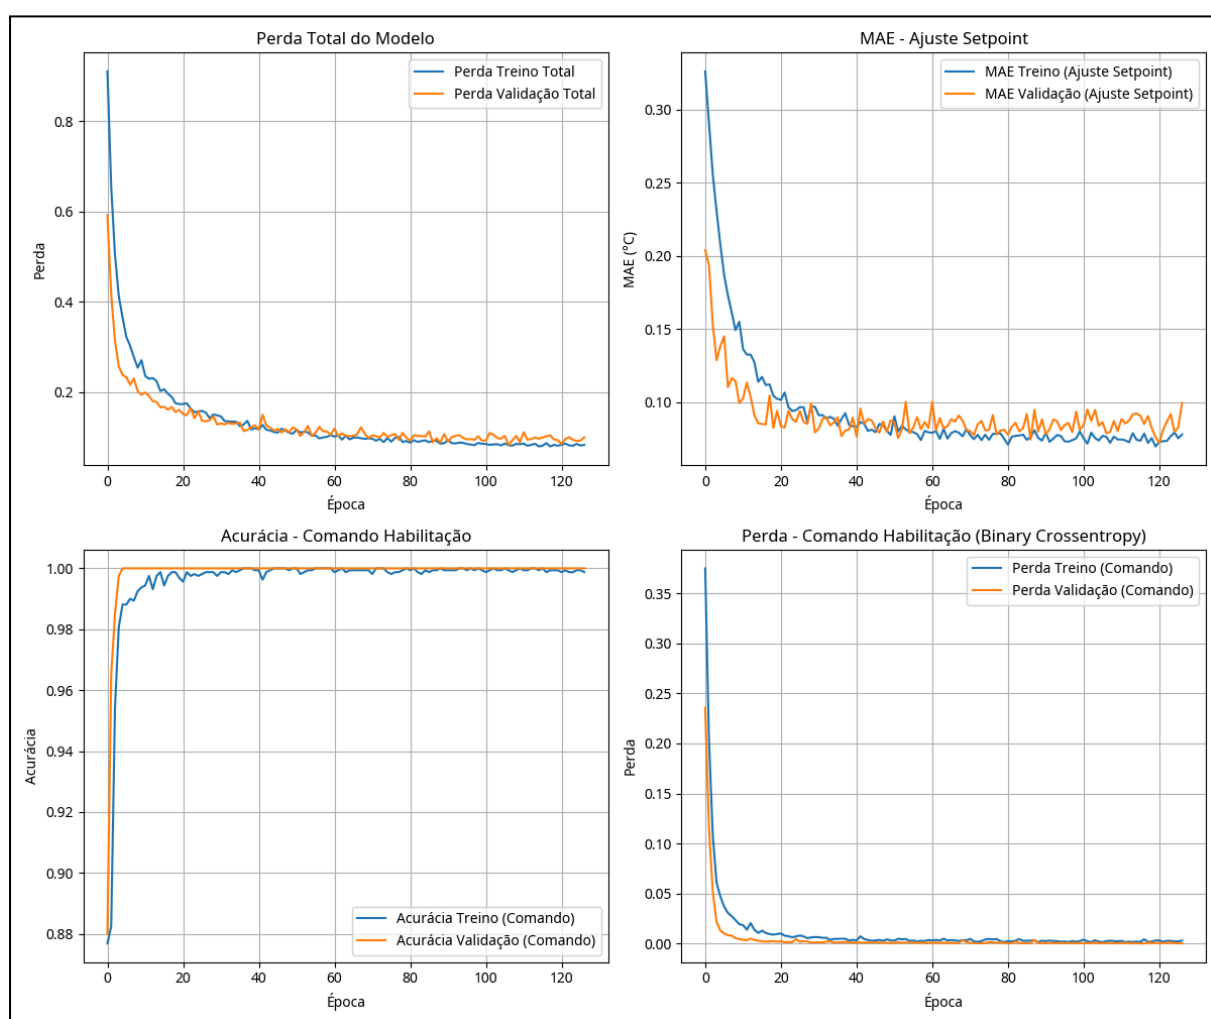


Figura 02 -Resultados do treinamento MAE/Acurácia da Rede Neural
Fonte: Elaboração do autor

Os resultados do treinamento demonstraram desempenho satisfatório do modelo proposto. A Figura 02 apresenta as curvas de perda e métricas para as tarefas de ajuste de setpoint (regressão) e habilitação do Chiller (classificação binária).

Observa-se, na perda total do modelo, uma rápida convergência nas primeiras 20 épocas, com estabilização em valores reduzidos e sem divergência relevante entre treino e validação, indicando boa capacidade de generalização. O erro absoluto médio (MAE) para o ajuste de setpoint apresentou queda inicial acentuada, estabilizando-se em torno de 0,05–0,10 °C, o que evidencia elevada precisão na previsão do setpoint.

Para a tarefa de classificação binária, a acurácia alcançou níveis superiores a 98% já nas primeiras épocas, mantendo-se estável ao longo do treinamento. Paralelamente, a função de perda binária (*binary crossentropy*) reduziu-se para valores próximos de 0,02, com comportamento semelhante em treino e validação. Esses resultados demonstram que o modelo foi capaz de aprender a lógica de habilitação do sistema Chiller de forma consistente e sem sinais de sobreajuste.

Assim, os experimentos confirmam que a rede neural proposta obteve desempenho robusto tanto na previsão contínua do setpoint quanto na decisão binária de habilitação, em consonância com a literatura sobre aprendizado profundo aplicado a sistemas de controle (Goodfellow et al., 2016; Chollet, 2017).

Resultados e Discussão

Com o objetivo de avaliar a eficiência do modelo de rede neural proposto, elaborou-se uma comparação direta entre a carga térmica obtida a partir do setpoint inicial (definido de forma convencional) e a carga térmica calculada a partir do setpoint ajustado pela rede neural.

Para esta análise, foi construída uma tabela de testes (Tabela 01) a partir de dados simulados. Esses dados foram gerados de maneira controlada, buscando representar condições de operação que, embora artificiais, são condizentes com a realidade prática de um sistema de resfriamento com Chiller. Essa estratégia permitiu avaliar de forma controlada o comportamento do modelo em diferentes cenários de entrada, sem depender apenas de medições empíricas sujeitas a variações ambientais.

A Tabela 01 apresenta variáveis fundamentais como temperatura ambiente, temperatura de entrada e saída do Chiller, pressão da água de saída, setpoint inicial, ajuste de setpoint previsto pela rede neural e comando de habilitação. Essas variáveis constituem a base para o cálculo da carga térmica (Q), conforme a equação (01):

Equação (01):

$$Q \text{ (kW)} = \text{vazão_mássica} * \text{calor_específico} * \text{delta_T}$$

- vazão mássica do fluido (kg/s).
- calor específico da água (aproximadamente 4,186 kJ/kg·K).
- Delta T: representa a diferença entre a temperatura de entrada e de saída da água no Chiller (°C ou em K).

Tabela 01. Amostra do nosso banco de dados para teste

temp_a mb	temp_ent_c hiller	temp_saida_ chiller	pressao_a gua_saida	setpoint _inicial	status _bom ba_1	status_ bomba _2	status_v alvula_b loq	ajuste_set point_pred	comando habilita predição
12,44	5,97	5,97	5,00	13,26	0,00	0,00	1,00	-0,01	0,00
8,15	27,30	25,71	2,35	12,36	0,00	1,00	0,00	0,00	0,00
39,18	35,69	34,60	2,07	11,53	0,00	1,00	0,00	0,00	0,00
40,43	10,80	10,80	2,91	8,16	1,00	0,00	0,00	0,00	0,00
31,28	13,18	11,73	1,81	6,03	0,00	1,00	0,00	0,00	0,00
30,21	14,14	5,40	3,95	10,44	1,00	1,00	1,00	1,38	1,00
44,29	16,29	16,29	1,71	7,25	1,00	1,00	0,00	0,00	0,00
37,96	31,41	31,41	1,61	9,38	0,00	0,00	1,00	-0,01	0,00
9,06	7,96	6,86	2,41	8,53	1,00	0,00	1,00	0,01	0,00
7,51	39,68	37,81	2,60	7,71	0,00	0,00	1,00	0,00	0,00
21,78	10,21	10,21	4,73	12,26	0,00	0,00	1,00	0,00	0,00
19,26	35,64	26,89	3,17	11,04	1,00	1,00	1,00	-1,44	1,00
28,79	6,37	5,64	2,82	7,81	0,00	1,00	1,00	0,00	0,00
7,30	8,94	7,32	3,06	5,43	0,00	0,00	1,00	0,00	0,00
34,33	15,18	13,22	4,73	14,57	1,00	0,00	1,00	0,00	0,00
23,44	36,60	36,60	1,20	11,95	0,00	0,00	0,00	-0,01	0,00
28,50	37,21	28,40	4,48	7,72	1,00	1,00	1,00	-2,03	1,00
32,29	5,71	3,72	2,21	14,64	1,00	0,00	0,00	-0,02	0,00
36,17	31,67	31,67	3,25	5,78	1,00	0,00	1,00	0,01	0,00

Fonte: Elaboração do autor

A partir dessa formulação, é possível comparar, de forma quantitativa, o impacto energético entre a manutenção do setpoint inicial e o ajuste realizado pela rede neural.

Para exemplificar o raciocínio teórico, foram selecionadas duas amostras da Tabela 01. Nessas linhas, calculou-se a carga térmica com base no setpoint convencional e comparou-se com o setpoint modificado pela rede neural, destacando as diferenças em termos de consumo energético (kW). Essa análise possibilita discutir, em bases concretas, se a rede neural proporciona de fato uma melhoria na eficiência energética e, consequentemente, uma redução no consumo elétrico do sistema.

Com base na Equação (01), realizou-se uma comparação pontual entre os cenários de setpoint inicial e setpoint ajustado pela rede neural. A análise abaixo utiliza as linhas 06 e 17 da Tabela 01 como estudo de caso.

Linha 06 (amostra da Tabela 01).

Nesta condição, a rede neural elevou levemente o setpoint em relação ao valor inicial, reduzindo o Delta T efetivo e, por consequência, a carga térmica processada. A carga térmica calculada com o setpoint inicial foi de 154,84 kW, enquanto com o setpoint ajustado pela rede neural foi de 97,03 kW. Observa-se, portanto, uma redução de 57,81 kW, o que corresponde a aprox. 37,33% de diminuição da carga térmica. Esse comportamento é consistente com a hipótese de que a rede neural evita sobre-resfriamentos desnecessários, aproximando o sistema de uma condição de operação energeticamente mais eficiente.

Linha 17 (amostra da Tabela 01).

Neste cenário, a rede neural resultou em um setpoint que aumentou o Delta T efetivo frente ao setpoint inicial, elevando a carga térmica requerida. A carga térmica com setpoint inicial foi de 1234,60 kW, enquanto com o setpoint ajustado pela rede neural atingiu 1319,70 kW. Houve, assim, um acréscimo de 85,10 kW, equivalente a aprox. 6,89% de aumento da carga térmica. Tal resultado indica que, sob determinadas combinações de variáveis (temperatura de entrada/saída, condições hidráulicas e limites operacionais), o ajuste ótimo de setpoint pode priorizar condições de controle/estabilidade (ou restrições operacionais) em detrimento de uma redução imediata de carga, o que é um trade-off conhecido em estratégias de controle avançado.

Os dois exemplos evidenciam que o ajuste de setpoint pela rede neural pode reduzir substancialmente a carga térmica (linha 06), mas também pode elevá-la em cenários específicos (linha 17), dependendo do estado do sistema. Em termos de eficiência, a economia em kW tende a ocorrer quando o ajuste reduz Delta T mantendo o atendimento da

demanda térmica. Já o aumento de kW pode refletir restrições de operação (p. ex., condições de conforto, estabilidade do controle ou requisitos de habilitação do equipamento) que a rede busca respeitar. Em um horizonte operacional, a economia líquida deve ser avaliada no conjunto de cenários, e não ponto a ponto, para capturar a contribuição média do algoritmo de otimização de setpoint sobre o consumo energético.

É importante destacar que o ajuste ótimo de setpoint pela rede neural não visa apenas reduzir a carga térmica em todos os instantes, mas sim equilibrar múltiplos objetivos de operação. Em determinadas situações, o algoritmo pode priorizar condições de controle e estabilidade operacional em detrimento da redução imediata da carga.

Por exemplo, setpoints excessivamente agressivos podem induzir oscilações de temperatura e aumento no número de ciclos de partida/parada, comprometendo a vida útil dos equipamentos e até elevando o consumo energético devido a transientes (ASHRAE, 2021). Além disso, a manutenção de condições de conforto térmico (ASHRAE Standard 55) e o respeito às restrições de operação dos chillers e bombas são aspectos fundamentais para evitar riscos como cavitação, congelamento de água e acionamento de alarmes (Cao et al., 2020).

Esse comportamento é consistente com estratégias de controle preditivo e multiobjetivo, em que o algoritmo procura a solução ótima ao longo do tempo, considerando não apenas a economia instantânea de energia, mas também a estabilidade, segurança e confiabilidade do sistema (Ma et al., 2012; Afram & Janabi-Sharifi, 2014).

Assim, o aumento pontual da carga térmica em alguns cenários (como observado na linha 17) pode ser interpretado não como uma ineficiência, mas como uma decisão ótima global, na qual a rede neural equilibra eficiência energética e robustez operacional.

Simulação do Modelo em 100 Cenários com Dados Sintéticos:

Para validar a capacidade de generalização da rede neural desenvolvida, foi realizada uma simulação envolvendo 100 cenários distintos, construídos a partir de dados sintéticos refinados, de modo a representar condições próximas da operação real de sistemas de climatização. O procedimento de simulação considerou como premissa a atuação de um operador humano na definição do setpoint inicial de temperatura, a partir do qual a rede neural propôs ajustes dinâmicos visando a otimização do desempenho energético do Chiller.

Dois arranjos experimentais foram avaliados:

(i) um primeiro, em que a habilitação do Chiller foi realizada de forma condicionada às decisões da rede neural, de acordo com a correção aplicada sobre o setpoint inicial, conforme a figura 03;

(ii) um segundo, no qual o Chiller foi forçado a permanecer habilitado em todos os cenários, permitindo uma comparação direta dos impactos do controle neural sobre a carga térmica demandada, conforme figura 04.

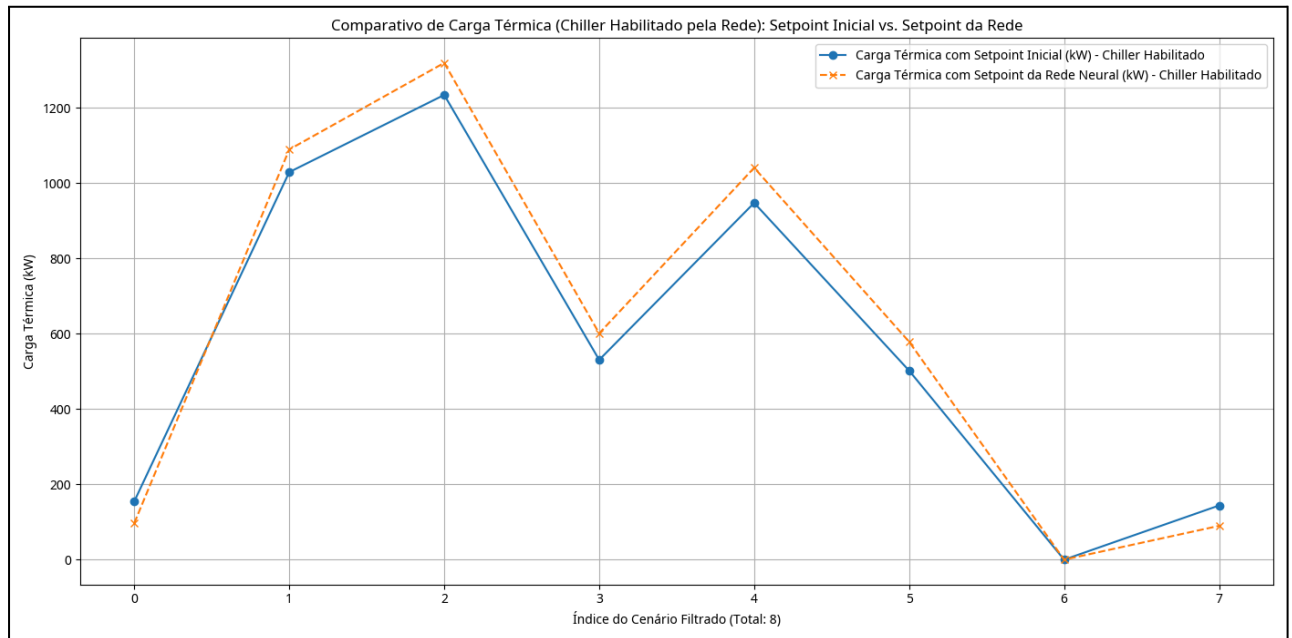


Figura 03. Comparativo de carga térmica Setpoint inicial x Setpoint Rede
Fonte: Elaboração do autor

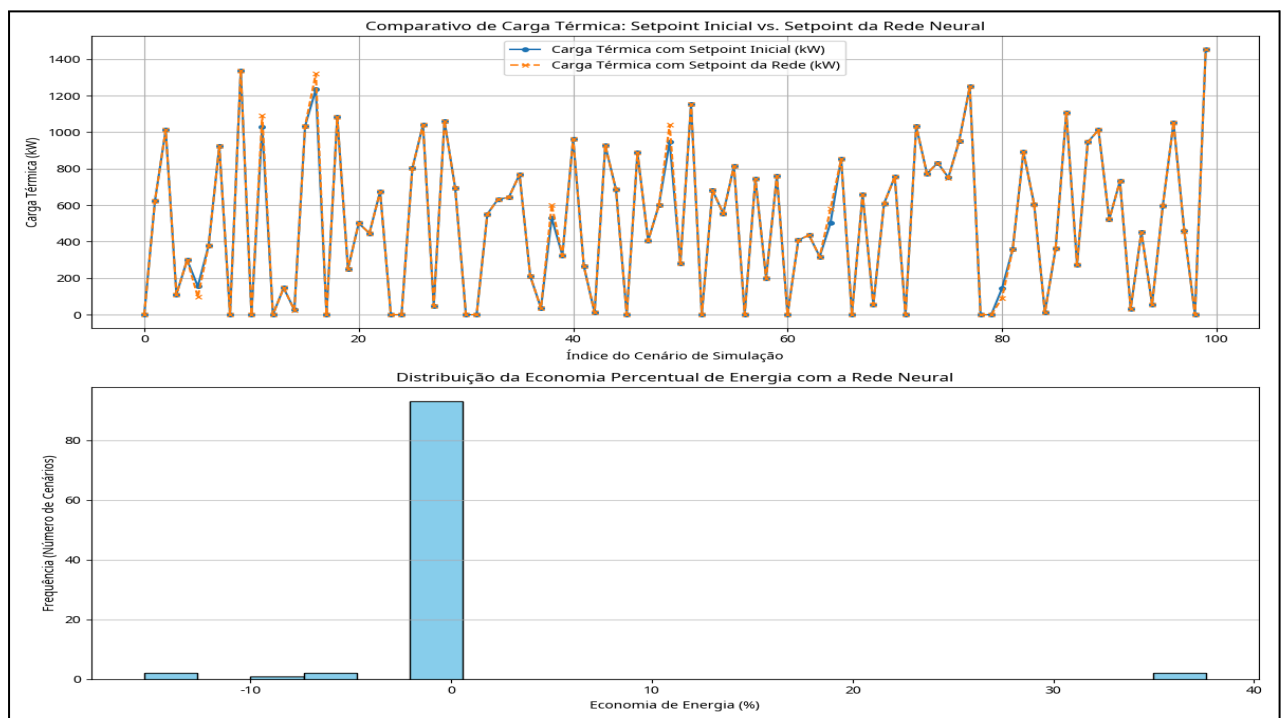


Figura 04. Comparativo de carga térmica Setpoint inicial x Setpoint Rede, todos os pontos habilitados
Fonte: Elaboração do autor

Os resultados, representados no gráfico, evidenciam que o modelo apresenta capacidade de ajuste e correção sobre o setpoint inicial, conforme figuras 03 e 04, refletindo em respostas distintas de carga térmica em função do comportamento do sistema. Em uma fração dos cenários, observou-se potencial de economia de energia, decorrente da atuação mais precisa da rede ao avaliar as condições operacionais e aplicar correções incrementais (positivas ou negativas) sobre o valor de referência. No entanto, verificou-se que em grande parte dos cenários a atuação da rede neural resultou em aumento de consumo energético, indicando que, embora o modelo seja capaz de aprender padrões e propor ajustes consistentes, ainda apresenta limitações quanto à robustez em cenários altamente variáveis.

Esse comportamento reforça a necessidade de aperfeiçoamento do treinamento da rede, bem como da inclusão de variáveis adicionais que possam melhor representar o estado do sistema térmico-hidráulico. Apesar dessas limitações, os resultados demonstram que o modelo possui capacidade de generalização inicial e que, com ajustes metodológicos, pode se consolidar como uma estratégia promissora para otimização do setpoint e redução do consumo energético em sistemas de resfriamento.

Simulação com Dados Reais de Temperatura – São Bernardo do Campo (10/05/2024):

Para avaliar o desempenho da rede neural em condições próximas à operação real, foi realizada uma simulação utilizando dados de temperatura ambiente registrados na cidade de São Bernardo do Campo (SP), no dia 10 de maio de 2024. As informações meteorológicas foram obtidas por meio da API Open-Meteo, garantindo confiabilidade e representatividade dos valores de entrada ao longo de um ciclo completo de 24 horas.

Nos cenários analisados, conforme figura 05, o chiller foi habilitado pela rede neural em 24 intervalos de tempo, conforme mostrado na tabela 02, correspondendo às variações de demanda ao longo do dia. Os resultados obtidos demonstraram:

- Carga térmica total com setpoint inicial (referência): 40.732,11 kW;
- Carga térmica total com setpoint ajustado pela rede neural: 40.905,03 kW;
- Diferença absoluta de consumo: +172,93 kW;
- Variação percentual: +0,42% em relação ao controle de referência.

Tabela 02. Banco de dados com entradas de temperatura ambiente de SBC

hora_medicao	temperatura_ambiente_c	temperatura_entrada_chiller_c	temperatura_saida_chiller_c	pressao_agua_saida_bar	setpoint_inicial_c	status_bomba_primaria	status_bomba_secundaria	status_valvula_bloqueio	ajuste_setpoint_pred_c	comando_habilitacao_pred_prob
2024-05-10T00:00	19,6	31,67	2,34	4,65	6,54	1	1	1	1,0855	1
2024-05-10T01:00	19,8	18,25	13,49	2,02	5,86	1	1	1	-1,0399	1
2024-05-10T02:00	19,6	6,21	4,1	4,81	4,42	1	1	1	0,9747	1
2024-05-10T03:00	19,4	24,79	3,87	1,99	14,24	1	1	1	1,6406	1
2024-05-10T04:00	19,3	21,07	10,97	3,43	13,24	1	1	1	0,8134	1
2024-05-10T05:00	19,2	29,92	3,69	1,56	4,14	1	1	1	0,2692	1
2024-05-10T06:00	19,1	17,5	11,61	2,74	12,1	1	1	1	0,2442	1
2024-05-10T07:00	19,1	18,33	14,77	2	11,98	1	1	1	-1,4013	1
2024-05-10T08:00	19	24,41	14,86	2,33	11,23	1	1	1	-1,6462	1
2024-05-10T09:00	19,1	17,09	11,43	2,43	10,29	1	1	1	-0,5327	1
2024-05-10T10:00	19,2	29,29	12,3	4,45	8,34	1	1	1	-1,5751	1
2024-05-10T11:00	20,2	39,09	25,8	4,86	6,35	1	1	1	-2,0066	1
2024-05-10T12:00	21,8	21,82	1,36	3,17	12,78	1	1	1	1,7433	1
2024-05-10T13:00	22,5	26,54	7,03	4,31	7,24	1	1	1	-0,3628	1
2024-05-10T14:00	23,6	33,12	17,2	3,52	4,79	1	1	1	-1,7659	1
2024-05-10T15:00	25,1	34,22	9,73	2,15	12,18	1	1	1	-0,2128	1
2024-05-10T16:00	26,3	15,4	7,5	3,09	10	1	1	1	1,1668	1
2024-05-10T17:00	27,1	11,54	10,77	4,18	10,12	1	1	1	0,2439	1
2024-05-10T18:00	27,4	23,24	6,6	2	9,37	1	1	1	0,7441	1

Fonte: Elaboração do autor

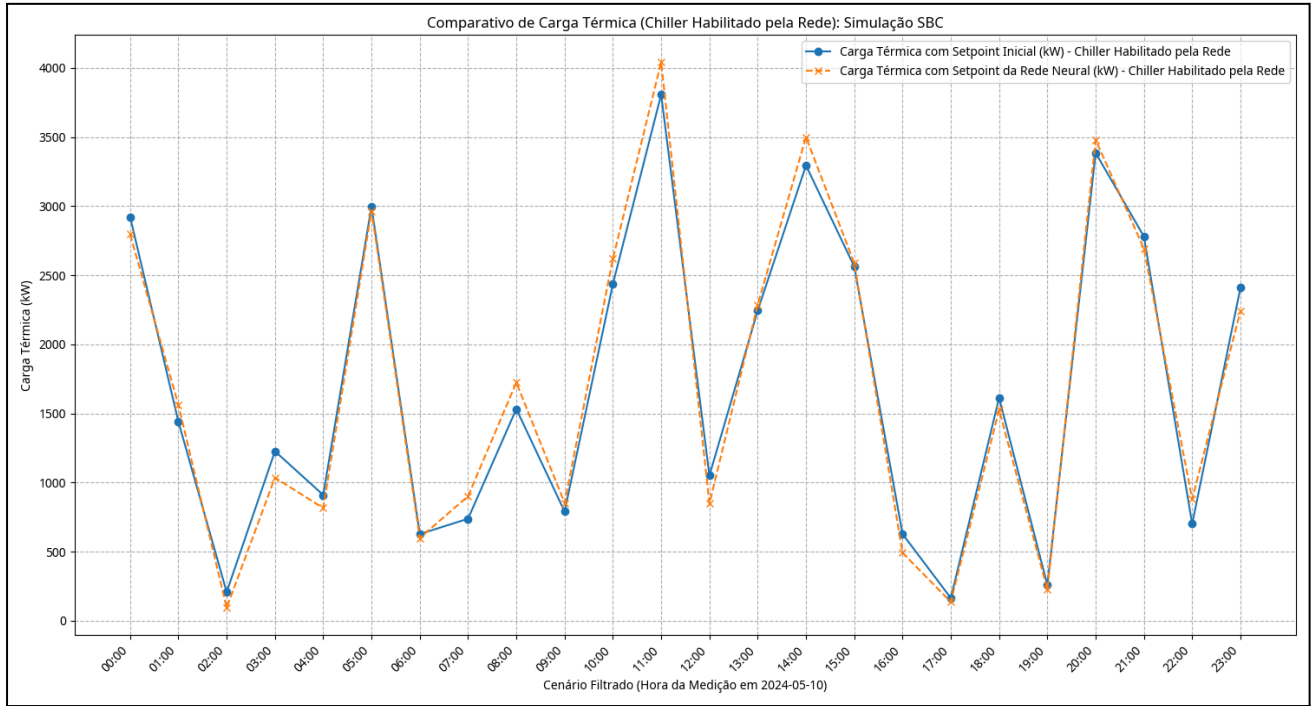


Figura 05 - Comparativo de carga térmica Setpoint inicial x Setpoint Rede, todos os pontos habilitados, analisando as entradas de temperatura em SBC

Fonte: Elaboração do autor

Observa-se que, ao considerar dados reais de temperatura ambiente, o desempenho da rede neural não apresentou ganhos expressivos de economia energética. Pelo contrário, foi registrado um leve aumento de consumo (0,42%), o que indica que o modelo, nessa configuração, priorizou a manutenção da estabilidade operacional do chiller em detrimento da redução imediata da carga térmica.

A análise evidencia que a rede neural, quando submetida a condições dinâmicas de um dia real de operação, manteve coerência em seu padrão de decisão, mas não apresentou vantagem significativa em termos de economia de energia. Esse resultado sugere que ajustes adicionais no processo de treinamento, assim como a incorporação de variáveis contextuais (por exemplo, ocupação, carga parcial do edifício ou tarifação horária da energia elétrica), podem ser necessários para ampliar os benefícios de eficiência do modelo.

Conclusão

O presente trabalho teve como objetivo investigar a aplicação de redes neurais artificiais (RNA) no ajuste automático de setpoints e habilitação de chillers, com foco na otimização do consumo energético em sistemas de climatização. A pesquisa apresentou uma metodologia estruturada de desenvolvimento, treinamento e validação do modelo, explorando tanto dados sintéticos, em cenários controlados, quanto dados reais de temperatura ambiente coletados em São Bernardo do Campo.

Os resultados confirmaram a viabilidade do uso de RNA para controle inteligente de chillers, evidenciando que o modelo foi capaz de aprender padrões complexos e realizar previsões consistentes. Nos experimentos com dados simulados, observou-se que a rede neural, em determinados cenários, conseguiu reduzir significativamente a carga térmica do sistema, demonstrando potencial de economia energética. Contudo, em outros casos, verificou-se aumento do consumo, revelando que a otimização é condicional às condições de operação e depende diretamente da qualidade e representatividade dos dados de entrada.

Na simulação com dados reais de 24 horas, constatou-se que o desempenho do modelo manteve coerência, mas não garantiu economia significativa em todos os casos. Esse achado reforça que, embora o controlador inteligente representa um avanço promissor, seu desempenho depende do refinamento contínuo do treinamento, da inclusão de variáveis adicionais (como perfil de ocupação, carga térmica parcial e tarifação horária de energia elétrica) e da calibração em cenários específicos.

As contribuições principais deste estudo incluem:

- A proposição de uma metodologia replicável para desenvolvimento de controladores inteligentes baseados em RNA;
- A demonstração experimental do comportamento do modelo em diferentes cenários, evidenciando seus pontos fortes e limitações;
- A integração entre fundamentos teóricos de aprendizado profundo e aplicações práticas em HVAC, com foco na eficiência energética.

Como desdobramentos futuros, recomenda-se:

- A utilização de bases de dados reais mais amplas e diversificadas, abrangendo diferentes condições climáticas e operacionais;
- A exploração de arquiteturas híbridas de controle, como o controle preditivo baseado em modelos (MPC) combinado a RNA;

- A aplicação prática em CLPs e controladores comerciais de chillers, de modo a validar em campo a robustez e a eficiência do modelo;
- A análise de impacto econômico considerando custos energéticos e manutenção preventiva.

Conclui-se, portanto, que o trabalho atingiu seus objetivos ao demonstrar que redes neurais podem ser aplicadas como ferramenta de suporte ao controle inteligente de chillers. Embora ainda existam limitações a superar, os resultados obtidos reforçam o potencial dessa abordagem como alternativa inovadora para a eficiência energética e sustentabilidade em sistemas de climatização.

Agradecimento

Agradeço a minha querida esposa, pela dedicação, cuidado e suporte em todos os momentos – sua parceria foi fundamental para que este trabalho se tornasse realidade. Agradeço aos meus pais por ter me dado a base e a determinação em sempre seguir em frente. E, acima de tudo, agradeço a Jesus Cristo, por ser meu pastor e não deixar nada faltar na vida da minha família.

Referências

AFRAM, A.; JANABI-SHARIFI, F. Artificial neural network-based control of HVAC systems. *Energy and Buildings*, v. 77, p. 403-414, 2014.

ALMEIDA, Ronaldo. Como definir uma CAG eficiente? Portal EA – Engenharia e Arquitetura, 23 jan. 2020. Disponível em: <https://www.engenhariaearquitectura.com.br/2020/01/como-definir-uma-cag-eficiente>. Acesso em: 30 mar. 2024.

ASHRAE. Handbook—HVAC applications. Atlanta: American Society of Heating, Refrigerating and Air-Conditioning Engineers, 2019.

ASHRAE. Fundamentals handbook. Atlanta: American Society of Heating, Refrigerating and Air-Conditioning Engineers, 2016.

ÅSTRÖM, Karl Johan; MURRAY, Richard M. Feedback systems: an introduction for scientists and engineers. Princeton: Princeton University Press, 2008. Disponível em: https://www.cds.caltech.edu/~murray/books/AM05/pdf/am08-complete_28Sep12.pdf. Acesso em: 1 abr. 2024.

BLOG DO FRIO. Retrofit e manutenção preventiva elevam eficiência de centrais de água gelada. 4 out. 2018. Disponível em: <https://blogdofrio.com.br/retrofit-e-manutencao-preventiva-elevam-eficiencia-de-centrais-de-a-gua-gelada/>. Acesso em: 28 abr. 2025.

CARRIER. Chiller systems: principles and applications. Syracuse: Carrier Corporation, 2019.

CONBRAVA – Congresso Brasileiro de Refrigeração, Ar Condicionado, Ventilação, Aquecimento e Tratamento de Ar. XVI Congresso Brasileiro de Refrigeração, Ar Condicionado, Ventilação, Aquecimento e Tratamento de Ar. São Paulo Expo, 10–13 set. 2019. Disponível em: https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto_54.pdf. Acesso em: 30 mar. 2024.

CONBRAVA – Congresso Brasileiro de Refrigeração, Ar Condicionado, Ventilação, Aquecimento e Tratamento de Ar. XVI Congresso Brasileiro de Refrigeração, Ar Condicionado, Ventilação, Aquecimento e Tratamento de Ar. São Paulo Expo, 10–13 set. 2019. Disponível em: https://schenautomacao.com.br/abrava/anais/files/trabalhocompleto_61.pdf. Acesso em: 30 mar. 2024.

DOE – Department of Energy. Buildings energy data book. Washington, DC: U.S. Department of Energy, 2012.

EXPERT ACADEMY. Funções de ativação: definição, características e quando usar cada uma. 25 maio 2020. Disponível em: <https://iaexpert.academy/2020/05/25/funcoes-de-ativacao-definicao-caracteristicas-e-quando-usar-cada-uma/>. Acesso em: 28 abr. 2025.

FIAMETTI, Rafael Augusto. Estudo de caso: eficiência energética em sistemas de climatização por água gelada. 2018. Disponível em: https://repositorio.utfpr.edu.br/jspui/bitstream/1/18500/1/CT_CEEFE_V_2016_05.pdf. Acesso em: 1 abr. 2024.

MAITHRA, Raghu; SCHMIDT, Eric. A survey of deep learning for scientific discovery. arXiv, 2020. Disponível em: <https://arxiv.org/pdf/2003.11755.pdf>. Acesso em: 30 mar. 2024.

MERCATO AUTOMAÇÃO. Automação predial e eficiência energética para centrais de água gelada. São Paulo, 16 ago. 2023. Disponível em: <https://www.mercatoautomacao.com.br/blogs/novidades/automacao-predial-e-eficiencia-energetica-para-centrais-de-agua-gelada>. Acesso em: 30 mar. 2024.

QUEL DE AZEVEDO NETO, Flávio. Automação de uma central de água gelada para climatização de salas de cinemas: um estudo de caso. 2023. Monografia (Graduação em Engenharia de Controle e Automação) – Universidade Federal de Ouro Preto, Ouro Preto, 2023. Disponível em: https://www.monografias.ufop.br/bitstream/35400000/6001/6/MONOGRAFIA_Automa%c3%a7%c3%a3oCentral%c3%81gua.pdf. Acesso em: 1 abr. 2024.

REMESSA ONLINE. Linguagem R: entenda como funciona e principais aplicações. São Paulo, 1 maio 2023. Disponível em: <https://www.remessaonline.com.br/blog/linguagem-r-entenda-como-funciona-e-principais-aplicacoes/>. Acesso em: 1 abr. 2024.

ZHANG, L. et al. PID vs. AI-based control in HVAC systems. Energy, v. 197, p. 117245, 2020.

ZHAO, Y. et al. Fault detection in chillers using neural networks. Building and Environment, v. 167, p. 106462, 2020.

LI, X. et al. Deep learning for smart HVAC control. Applied Energy, v. 291, p. 116823, 2021.

CHOLLET, F. Deep Learning with Python. Manning Publications, 2017.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. MIT Press, 2016.

NIELSEN, M. Neural Networks and Deep Learning. Determination Press, 2015.

AFRAM, A.; JANABI-SHARIFI, F. Theory and applications of HVAC control systems – A review of model predictive control (MPC). Building and Environment, v. 72, p. 343-355, 2014. DOI: <https://doi.org/10.1016/j.buildenv.2013.11.016>

QIU, S.; FENG, C.; WANG, S.; LIU, Y. A review of HVAC control strategies using advanced data-driven approaches. Energy and Buildings, v. 241, p. 110944, 2021. DOI: <https://doi.org/10.1016/j.enbuild.2021.110944>

ÅSTRÖM, K. J.; HÄGGLUND, T. Advanced PID control. Research Triangle: ISA–The Instrumentation, Systems, and Automation Society, 2006.

AZEVEDO NETO, Flávio Quiel. Automação de uma central de água gelada para climatização de salas de cinemas: um estudo de caso. 2023. 71 f. Monografia (Graduação em Engenharia Elétrica) – Instituto de Ciências Exatas e Aplicadas, Universidade Federal de Ouro Preto, João Monlevade, 2023.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.

KINGMA, Diederik P.; BA, Jimmy. Adam: a method for stochastic optimization. arXiv preprint arXiv:1412.6980, 2015. Disponível em: <https://arxiv.org/abs/1412.6980>
. Acesso em: 21 ago. 2025.